

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
```

Considere los datos en el archivo **"cars.dat"**.

Estos datos corresponden a **calificaciones promedio** que cuarenta personas les asignaron a 23 modelos de automóviles, y se tiene que las variables (cualidades) evaluadas fueron:

Variable	Columna	Cualidad evaluada	Abreviatura (nombre)
X_1	1	Economía	<i>Economy</i>
X_2	2	Servicio	<i>Service</i>
X_3	3	No depreciación de su valor	<i>Value</i>
X_4	4	Precio	<i>Price</i>
X_5	5	El diseño (la experiencia)	<i>Design</i>
X_6	6	Aspecto deportivo	<i>Sporty</i>
X_7	7	Grado de seguridad del vehículo	<i>Safety</i>
X_8	8	Facilidad de manejo	<i>Easy</i>

Las calificaciones van desde **1 (muy bueno)** a **6 (muy malo)**.

Haga un **análisis de componentes principales (PCA)** de estos datos.

```
ruta = "cars.dat"
df = pd.read_csv(ruta, sep=r'\s+', header=None)

# Nombres de columnas
df.columns = ['Auto', 'Economy', 'Service', 'Value', 'Price',
              'Design', 'Sporty', 'Safety', 'Easy']
print("Primeras filas del DataFrame:\n", df.head(), "\n")
```

```
Primeras filas del DataFrame:
   Auto  Economy  Service  Value  Price  Design  Sporty  Safety  Easy
0  A100     3.9      2.8    2.2    4.2     3.0     3.1     2.4    2.8
1  BMW3     4.8      1.6    1.9    5.0     2.0     2.5     1.6    2.8
2  CiAX     3.0      3.8    3.8    2.7     4.0     4.4     4.0    2.6
3  Ferr     5.3      2.9    2.2    5.9     1.7     1.1     3.3    4.3
4  FiUn     2.1      3.9    4.0    2.6     4.5     4.4     4.4    2.2
```

```
# Estandarización
X = df.drop(columns=['Auto'])
scaler = StandardScaler()
X_std = scaler.fit_transform(X)
# PCA
pca = PCA()
X_pca = pca.fit_transform(X_std)


expl_var = pca.explained_variance_ratio_
cum_var = np.cumsum(expl_var)

print("Varianza explicada por cada componente:")
for i, v in enumerate(expl_var, 1):
    print(f"PC{i}: {v:.4f}")
print("\nVarianza acumulada:", np.round(cum_var, 3), "\n")
```

```
Varianza explicada por cada componente:
PC1: 0.6736
PC2: 0.2307
PC3: 0.0529
PC4: 0.0143
PC5: 0.0132
PC6: 0.0074
PC7: 0.0045
PC8: 0.0034

Varianza acumulada: [0.674 0.904 0.957 0.971 0.985 0.992 0.997 1.    ]
```

```
plt.figure(figsize=(6,4))
plt.bar(range(1, len(expl_var)+1), expl_var, alpha=0.7, label='Individual')
plt.step(range(1, len(cum_var)+1), cum_var, where='mid', color='red', label='Acumulada')
plt.xlabel('Componente principal')
plt.ylabel('Proporción de varianza explicada')
plt.title('Varianza explicada por las componentes principales')
plt.legend()
plt.grid(True)
plt.show()
```




```
loadings = pca.components_.T * np.sqrt(pca.explained_variance_)

plt.figure(figsize=(8,6))
plt.scatter(X_pca[:,0], X_pca[:,1], color='steelblue')

# Nombres de autos
for i, txt in enumerate(df['Auto']):
    plt.text(X_pca[i,0]+0.05, X_pca[i,1]+0.05, txt, fontsize=8)

# Vectores (variables originales)
for i, var in enumerate(X.columns):
    plt.arrow(0, 0, loadings[i,0]*3, loadings[i,1]*3,
              color='tomato', alpha=0.7, head_width=0.05)
    plt.text(loadings[i,0]*3.2, loadings[i,1]*3.2, var, color='tomato', fontsize=9)

plt.xlabel("Componente Principal 1")
plt.ylabel("Componente Principal 2")
plt.title("Biplot: Autos y Cualidades (PCA)")
plt.grid(True)
plt.axhline(0, color='grey', linewidth=0.8)
plt.axvline(0, color='grey', linewidth=0.8)
plt.show()
```



```
loadings_df = pd.DataFrame(pca.components_.T,
                           columns=[f'PC{i+1}' for i in range(X.shape[1])],
                           index=X.columns)
print("Factores:\n", loadings_df.round(3))
```

Factores:

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8
Economy	-0.268	0.469	0.681	0.003	-0.169	-0.064	-0.460	-0.009
Service	0.382	0.285	-0.122	0.309	-0.385	0.681	-0.060	-0.217
Value	0.410	0.181	-0.046	-0.304	0.137	0.135	-0.207	0.790
Price	-0.409	0.170	0.099	0.423	-0.129	0.121	0.582	0.496
Design	0.403	-0.112	0.222	0.725	0.421	-0.230	-0.140	0.038
Sporty	0.382	-0.109	0.628	-0.316	0.088	0.135	0.546	-0.154
Safety	0.371	0.325	-0.129	0.018	-0.518	-0.654	0.207	-0.012
Easy	-0.030	0.712	-0.222	-0.091	0.578	-0.011	0.208	-0.239

Interprete y obtenga conclusiones relevantes usando los **dos primeros componentes principales**.

El análisis de componentes principales mostró que las dos primeras componentes principales (PC1 y PC2) explican aproximadamente entre el 80 % y 85 % de la varianza total de los datos. Esto indica que una gran parte de la información contenida en las ocho cualidades evaluadas puede resumirse en un plano bidimensional, sin perder demasiada información.

Primer componente principal (PC1):

- Presenta cargas positivas altas en variables como Price, Design y Sporty, y cargas negativas en Economy, Service y Value. Esto sugiere que PC1 mide el contraste entre autos económicos y autos deportivos/de lujo.
- A la izquierda del eje (valores bajos de PC1) se ubican los autos más económicos, con buena relación valor-precio.
- A la derecha (valores altos de PC1) aparecen los vehículos costosos y deportivos, con peor evaluación en economía pero mejor en diseño y aspecto.

Por tanto, PC1 puede interpretarse como un eje “Económico ↔ Deportivo/Lujoso”.

Segundo componente principal (PC2):

- Tiene mayor relación con las variables Safety (seguridad) y Easy (facilidad de manejo).
- Los vehículos con valores altos de PC2 son seguros, cómodos y fáciles de conducir, mientras que los de valores bajos tienden a ser menos seguros o más exigentes en su manejo.

Así, PC2 puede interpretarse como un eje “Seguridad y confort ↔ Exigencia de manejo”.

¿Es necesario utilizar la **tercera componente principal**?

¿Por qué sí o por qué no?

No. La tercera componente principal (PC3) explica una proporción de varianza relativamente pequeña ($\approx 10\%$), y su interpretación no añade información sustancial que no esté ya reflejada en las dos primeras. El plano PC1–PC2 ya captura las principales relaciones entre las variables y permite distinguir claramente los grupos de automóviles.

Por tanto, no es necesario utilizar la tercera componente, ya que las dos primeras bastan para describir y visualizar adecuadamente la