



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO.
IIMAS

Aprendizaje de Máquina

Semestre 2026-1.

D.C.C. Carlos Ignacio Hernández Castellanos

José Alberto Alonso González

Tarea 3

Integrantes:

- Villalón Pineda Luis Enrique

EJERCICIOS Y DEMOSTRACIONES

1. (20 puntos) Demuestre que la regla del SVM duro,

$$\arg \max_{\|w\|=1} \min_{i \in [m]} |\langle w, x_i \rangle + b| \quad \text{sujeto a} \quad \forall i, y_i (\langle w, x_i \rangle + b) > 0,$$

es equivalente a la siguiente formulación:

$$\arg \max_{\|w\|=1, b} \min_{i \in [m]} y_i (\langle w, x_i \rangle + b).$$

Sugerencia: Defina $\mathcal{G} = \{(w, b) : \forall i, y_i (\langle w, x_i \rangle + b) > 0\}$.

- a) Demuestre que

$$\arg \max_{\|w\|=1, b} \min_{i \in [m]} y_i (\langle w, x_i \rangle + b) \in \mathcal{G}.$$

- b) Demuestre que para todo $(w, b) \in \mathcal{G}$,

$$\min_{i \in [m]} y_i (\langle w, x_i \rangle + b) = \min_{i \in [m]} |\langle w, x_i \rangle + b|.$$

Sea un conjunto de entrenamiento separable linealmente

$$\{(x_i, y_i)\}_{i=1}^m, \quad y_i \in \{-1, +1\}.$$

Es decir, existe al menos un hiperplano que separa correctamente todos los ejemplos con un margen positivo. También decimos la restricción $\|w\| = 1$. Definimos, para $f_{w,b}(x) := \langle w, x \rangle + b$,

$$\gamma_{\text{sgn}}(w, b) := \min_{i \in [m]} y_i f_{w,b}(x_i), \quad \gamma_{\text{abs}}(w, b) := \min_{i \in [m]} |f_{w,b}(x_i)|,$$

y el conjunto de clasificadores que etiquetan bien a todos los puntos:

$$\mathcal{G} := \{(w, b) : \forall i \in [m], y_i f_{w,b}(x_i) > 0\}.$$

De esta manera queremos comparar lo siguientes incisos:

$$(P1) \quad \arg \max_{\|w\|=1, b} \gamma_{\text{abs}}(w, b) \quad \text{sujeto a} \quad (w, b) \in \mathcal{G};$$

$$(P2) \quad \arg \max_{\|w\|=1, b} \gamma_{\text{sgn}}(w, b).$$

Empecemos demostrando los incisos para después demostrar la equivalencia.

Lema .1 (P2). Sea $(w^*, b^*) \in \arg \max_{\|w\|=1, b} \gamma_{\text{sgn}}(w, b)$. Entonces $(w^*, b^*) \in \mathcal{G}$.

Demostración. Por separabilidad, existe $(\tilde{w}, \tilde{b})$ (que podemos normalizar a $\|\tilde{w}\| = 1$) tal que $y_i f_{\tilde{w}, \tilde{b}}(x_i) > 0$ para todo i , y por lo tanto $\gamma_{\text{sgn}}(\tilde{w}, \tilde{b}) = \min_i y_i f_{\tilde{w}, \tilde{b}}(x_i) > 0$. La optimización de (w^*, b^*) dado que $\gamma_{\text{sgn}}(w^*, b^*) \geq \gamma_{\text{sgn}}(\tilde{w}, \tilde{b}) > 0$.

Pero como $\gamma_{\text{sgn}}(w^*, b^*) = \min_i y_i f_{w^*, b^*}(x_i) > 0$, se sigue que $y_i f_{w^*, b^*}(x_i) > 0$ para todo i . Es decir, $(w^*, b^*) \in \mathcal{G}$. $\square$

Lema .2. Si $y \in \{-1, +1\}$ y $t \in \mathbb{R}$ satisfacen $yt > 0$, entonces $yt = |t|$.

Demostración. Del supuesto $yt > 0$ podemos decir que $y = (t)$ y $t \neq 0$. Entonces $yt = (t)t = |t|$. $\square$

Corolario .1 (Inciso (b)). Para todo $(w, b) \in \mathcal{G}$ se tiene

$$\min_i y_i f_{w,b}(x_i) = \min_i |f_{w,b}(x_i)|.$$

Demostración. Si $(w, b) \in \mathcal{G}$, entonces para cada i , $y_i f_{w,b}(x_i) > 0$ y por el Lema .2, $y_i f_{w,b}(x_i) = |f_{w,b}(x_i)|$. La identidad se mantiene al tomar mínimos en i . $\square$

Proposición .1 (Inciso (a) y equivalencia de (P1) y (P2)). Todo óptimo de (P2) pertenece a $\mathcal{G}$ y, por lo tanto, los conjuntos de soluciones de (P1) y (P2) coinciden.

Demostración. (Inciso (a)) El Lema .1 dice que

$$\arg \max_{\|w\|=1, b} \min_i y_i f_{w,b}(x_i) \subseteq \mathcal{G}.$$

Podemos verlo como, sea (w^*, b^*) óptimo de (P2). Por el Lema .1, $(w^*, b^*) \in \mathcal{G}$ además por el Corolario .1, $\gamma_{\text{sgn}}(w^*, b^*) = \gamma_{\text{abs}}(w^*, b^*)$, y lo mismo vale para todo $(w, b) \in \mathcal{G}$. Así, como (w^*, b^*) maximiza γ_{sgn} (en todo el dominio con $\|w\| = 1$), también maximiza γ_{abs} dentro de $\mathcal{G}$; por lo tanto es óptimo de (P1).

Ahora bien, de la misma manera, si $(\hat{w}, \hat{b}) \in \mathcal{G}$ es óptimo de (P1), entonces

$$\gamma_{\text{sgn}}(\hat{w}, \hat{b}) = \gamma_{\text{abs}}(\hat{w}, \hat{b}) = \max_{(w,b) \in \mathcal{G}, \|w\|=1} \gamma_{\text{abs}}(w, b) = \max_{(w,b) \in \mathcal{G}, \|w\|=1} \gamma_{\text{sgn}}(w, b).$$

Por el Lema .1, el máximo global de γ_{sgn} (con $\|w\| = 1$) se alcanza en $\mathcal{G}$, luego $(\hat{w}, \hat{b})$ también es óptimo de (P2). Por lo que queda probada la igualdad de conjuntos de soluciones. $\square$

Una noticia En el caso de que no se fijara $\|w\| = 1$, ambos objetivos serían no acotados, pues

$$\min_i y_i f_{\alpha w, \alpha b}(x_i) = \alpha \min_i y_i f_{w,b}(x_i), \quad \min_i |f_{\alpha w, \alpha b}(x_i)| = \alpha \min_i |f_{w,b}(x_i)|,$$

para todo $\alpha > 0$. La restricción $\|w\| = 1$ o si maximizáramos el margen geométrico; esta elimina la degeneración.

2. (20 puntos) Demuestre o refute la siguiente afirmación:

Existe un valor $\lambda > 0$ tal que, para toda muestra S de $m > 1$ ejemplos que sea separable por la clase de hiperplanos homogéneos, los algoritmos SVM duro y SVM blando (con parámetro λ) producen exactamente el mismo vector de pesos.

Proposición .2. *No existe un $\lambda > 0$ universal tal que, para toda muestra S de $m > 1$ ejemplos separable por la clase de hiperplanos homogéneos, los SVM duro y SVM blando (con parámetro λ) produzcan exactamente el mismo vector de pesos.*

Demostración. Trabajaremos con hiperplanos *homogéneos* es decir sin sesgo: clasificadores $x \mapsto \text{sign}(\langle w, x \rangle)$.

Formas primales.

$$(\text{Hard}) \quad \min_w \frac{1}{2} \|w\|^2 \quad \text{s.a.} \quad y_i \langle w, x_i \rangle \geq 1, \quad i = 1, \dots, m.$$

$$(\text{Soft}) \quad \min_{w, \xi \geq 0} \frac{1}{2} \|w\|^2 + \lambda \sum_{i=1}^m \xi_i \quad \text{s.a.} \quad y_i \langle w, x_i \rangle \geq 1 - \xi_i, \quad i = 1, \dots, m.$$

Entonces con eso definido demostraremos por contradicción que, dado cualquier $\lambda > 0$ fijo, existe una muestra separable S para la cual las soluciones son distintas.

Primero consideramos en $\mathbb{R}$ que la muestra

$$S_1 = \{(x_1 = 1, y_1 = +1), (x_2 = -1, y_2 = -1)\}.$$

Es separable por hiperplanos homogéneos (basta con $w = 1$ para que se cumpla) entonces para un factor de escala $\alpha > 0$, definimos la familia reescalada como:

$$S_\alpha = \{(\alpha, +1), (-\alpha, -1)\}.$$

Notemos que S_α sigue siendo separable por hiperplanos homogéneos para todo $\alpha > 0$.

Ahora si analizamos el costo del SVM duro en S_α . Las restricciones del duro son $y_i \langle w, \alpha x_i \rangle \geq 1$, que aquí se reducen a $\alpha w \geq 1$. El minimizador de norma es $w_{\text{hard}}(\alpha) = 1/\alpha$, con valor objetivo

$$J_{\text{hard}}(\alpha) = \frac{1}{2} \|w_{\text{hard}}(\alpha)\|^2 = \frac{1}{2} \cdot \frac{1}{\alpha^2}.$$

Mientras que la cota superior para el SVM blando en S_α . En el blando, el punto $(w, \xi) = (0, \xi_1 = \xi_2 = 1)$ es posible porque $y_i \langle 0, \alpha x_i \rangle = 0 \geq 1 - \xi_i = 0$. Por lo que su costo es

$$J_{\text{soft}}(\alpha) \leq \frac{1}{2} \|0\|^2 + \lambda(\xi_1 + \xi_2) = 2\lambda.$$

Ahora tenemos que elegir el α . Fijado $\lambda > 0$, escojamos $\alpha > 0$ tal que

$$J_{\text{hard}}(\alpha) = \frac{1}{2\alpha^2} > 2\lambda.$$

Por ejemplo, cualquier $\alpha < \frac{1}{2\sqrt{\lambda}}$ satisface la desigualdad.

De esta manera con esta elección de α ,

$$J_{\text{soft}}(\alpha) \leq 2\lambda < J_{\text{hard}}(\alpha).$$

Por lo tanto, el óptimo soft $(w_{\text{soft}}(\alpha), \xi_{\text{soft}}(\alpha))$ no puede coincidir con el de hard (que tendría $\xi \equiv 0$ y costo $J_{\text{hard}}(\alpha)$). En particular, $w_{\text{soft}}(\alpha) \neq w_{\text{hard}}(\alpha)$. Como vale para cualquier $\lambda > 0$ (solo basta con reescalar con un α suficientemente pequeño), de modo que no existe un λ universal que iguale ambos clasificadores para todas las muestras separables. $\square$

Nota .1. Si se permite que λ dependa de la muestra S , entonces para datos separables existe λ_S suficientemente grande tal que la solución soft $\xi_i = 0$ y coincide con la hard. Pero como lo que el enunciado pedía era un λ único y fijo para todas las muestras, lo cual es imposible por la invariancia de escala.

3. (20 puntos) Demuestre que para cualquier función f de dos variables vectoriales $x \in \mathcal{X}$ y $y \in \mathcal{Y}$, se cumple:

$$\min_{x \in \mathcal{X}} \max_{y \in \mathcal{Y}} f(x, y) \geq \max_{y \in \mathcal{Y}} \min_{x \in \mathcal{X}} f(x, y).$$

Demostremos dos proposiciones para poder demostrarlo

Proposición .3 (Desigualdad minimax con ínfimo y supremo). Sean $\mathcal{X}$ y $\mathcal{Y}$ conjuntos no vacíos y $f : \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}$ una función arbitraria. Entonces

$$\sup_{y \in \mathcal{Y}} \inf_{x \in \mathcal{X}} f(x, y) \leq \inf_{x \in \mathcal{X}} \sup_{y \in \mathcal{Y}} f(x, y).$$

Demostración. Definamos, para cada $y \in \mathcal{Y}$,

$$m(y) := \inf_{x \in \mathcal{X}} f(x, y),$$

y para cada $x \in \mathcal{X}$,

$$M(x) := \sup_{y \in \mathcal{Y}} f(x, y).$$

Primero veamos las acotaciones punto a punto. Es decir, por definición de ínfimo, para todo $x \in \mathcal{X}$ y todo $y \in \mathcal{Y}$,

$$m(y) \leq f(x, y).$$

De la misma manera, por definición de supremo, para todo $x \in \mathcal{X}$ y todo $y \in \mathcal{Y}$,

$$f(x, y) \leq M(x).$$

Combinando ambas desigualdades, para *todo* par (x, y) ,

$$m(y) \leq f(x, y) \leq M(x).$$

Ahora pasemos a extremos globales. Es decir, la desigualdad anterior implica que, para todo $x \in \mathcal{X}$ y todo $y \in \mathcal{Y}$,

$$m(y) \leq M(x).$$

Tomando el supremo en y del lado izquierdo (que lo hace más grande) y el ínfimo en x del lado derecho (que lo hace más pequeño), nos quedamos con la desigualdad:

$$\sup_{y \in \mathcal{Y}} m(y) \leq \inf_{x \in \mathcal{X}} M(x).$$

Reemplazando $m(y)$ y $M(x)$ por sus definiciones concluimos

$$\sup_{y \in \mathcal{Y}} \inf_{x \in \mathcal{X}} f(x, y) \leq \inf_{x \in \mathcal{X}} \sup_{y \in \mathcal{Y}} f(x, y).$$

□

Proposición .4 (Desigualdad minimax). *Si, además para cada $y \in \mathcal{Y}$ el ínfimo $\inf_x f(x, y)$ se alcanza (es decir existe $\min_x f(x, y)$), y para cada $x \in \mathcal{X}$ el supremo $\sup_y f(x, y)$ se alcanza (es decir existe $\max_y f(x, y)$), entonces*

$$\max_{y \in \mathcal{Y}} \min_{x \in \mathcal{X}} f(x, y) \leq \min_{x \in \mathcal{X}} \max_{y \in \mathcal{Y}} f(x, y).$$

Demostración. Cuando los extremos se alcanzan, se cumple $\sup_y \inf_x f = \max_y \min_x f$ y $\inf_x \sup_y f = \min_x \max_y f$. Aplicando la proposición anterior y sustituyendo supremos/ínfimos por máximos/mínimos, se llega a lo que queríamos. □

4. (20 puntos) Considere el problema de aprendizaje mediante SVM en el que algunos puntos de entrenamiento son más importantes que otros. Suponga que cada punto de entrenamiento está dado por una tripleta (x_i, y_i, p_i) , donde $0 \leq p_i \leq 1$ representa la importancia del i -ésimo punto. Reescriba el problema primal del SVM de modo que la penalización por clasificar incorrectamente un punto x_i sea ponderada por la prioridad p_i . Después, lleve esta modificación a través de la derivación de la solución dual.

Proposición .5 (SVM con ponderaciones). *Sea un conjunto de entrenamiento $\{(x_i, y_i, p_i)\}_{i=1}^m$ con $x_i \in \mathbb{R}^d$, $y_i \in \{-1, +1\}$ y prioridades $p_i \in [0, 1]$. Para un parámetro $C > 0$, el problema primal del SVM blando con penalización ponderada por p_i es*

$$\begin{aligned} \min_{w, b, \xi} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m p_i \xi_i \\ \text{s.a.} \quad & y_i (\langle w, x_i \rangle + b) \geq 1 - \xi_i, \quad i = 1, \dots, m, \\ & \xi_i \geq 0, \quad i = 1, \dots, m. \end{aligned} \tag{1}$$

Entonces su dual es

$$\begin{aligned} \max_{\alpha \in \mathbb{R}^m} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle \\ \text{s.a.} \quad & 0 \leq \alpha_i \leq C p_i, \quad i = 1, \dots, m, \\ & \sum_{i=1}^m \alpha_i y_i = 0, \end{aligned} \tag{2}$$

y, más generalmente, sustituyendo $\langle x_i, x_j \rangle$ por un núcleo $K(x_i, x_j)$.

Demostración. Primero veamos la Convexidad y forma primal. La función objetivo en (1) es suma de un término estrictamente convexo $\frac{1}{2}\|w\|^2$ y un término lineal en ξ . Las restricciones también son lineales, así que estamos ante un problema convexo. Como cumple Slater (es decir, la existencia de al menos un punto en el interior de la región factible que satisfaga estrictamente todas las restricciones de desigualdad), entonces habrá dualidad fuerte.

Ahora veamos el Lagrangiano, donde introducimos multiplicadores $\alpha_i \geq 0$ para las restricciones de margen $y_i(\langle w, x_i \rangle + b) \geq 1 - \xi_i$ y $\mu_i \geq 0$ para $\xi_i \geq 0$. El Lagrangiano es

$$\begin{aligned}\mathcal{L}(w, b, \xi; \alpha, \mu) &= \frac{1}{2}\|w\|^2 + C \sum_{i=1}^m p_i \xi_i - \sum_{i=1}^m \alpha_i (y_i(\langle w, x_i \rangle + b) - 1 + \xi_i) - \sum_{i=1}^m \mu_i \xi_i \\ &= \frac{1}{2}\|w\|^2 - \sum_{i=1}^m \alpha_i y_i \langle w, x_i \rangle - b \sum_{i=1}^m \alpha_i y_i + \sum_{i=1}^m \alpha_i + \sum_{i=1}^m \xi_i (C p_i - \alpha_i - \mu_i).\end{aligned}$$

Veamos si se cumplen las condiciones de estacionariedad. Si anulamos los gradientes respecto de variables primales:

(i) En w :

$$\nabla_w \mathcal{L} = w - \sum_{i=1}^m \alpha_i y_i x_i = 0 \implies w^* = \sum_{i=1}^m \alpha_i y_i x_i.$$

(ii) En b :

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^m \alpha_i y_i = 0 \implies \sum_{i=1}^m \alpha_i y_i = 0.$$

(iii) En cada ξ_i :

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = C p_i - \alpha_i - \mu_i = 0 \implies \mu_i = C p_i - \alpha_i.$$

Como $\mu_i \geq 0$, se deduce la *cota superior ponderada*

$$0 \leq \alpha_i \leq C p_i, \quad i = 1, \dots, m.$$

pasemos a la eliminación de variables primales en la función dual. Sustituyendo w^* en $\mathcal{L}$ se obtiene

$$\frac{1}{2}\|w^*\|^2 - \sum_{i=1}^m \alpha_i y_i \langle w^*, x_i \rangle = \frac{1}{2}\|w^*\|^2 - \langle w^*, w^* \rangle = -\frac{1}{2}\|w^*\|^2 = -\frac{1}{2}\left\| \sum_{i=1}^m \alpha_i y_i x_i \right\|^2.$$

Además, el término en b desaparece por la restricción $\sum_i \alpha_i y_i = 0$ y, gracias a la estacionariedad en ξ , el término con ξ se anula. Así, la función dual (a maximizar en α bajo las restricciones halladas) es

$$g(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle,$$

con $0 \leq \alpha_i \leq Cp_i$ y $\sum_i \alpha_i y_i = 0$, que coincide con (2). Y por dualidad fuerte, el óptimo dual coincide con el primal.

Aun que también tenemos ver las condiciones. De manera que además de estacionariedad y factibilidad primal/dual, se cumplen las holguras complementarias:

$$\alpha_i (y_i (\langle w^*, x_i \rangle + b^*) - 1 + \xi_i^*) = 0, \quad \mu_i^* \xi_i^* = 0.$$

En particular nos interesa:

- Si $0 < \alpha_i^* < Cp_i$, entonces $\mu_i^* > 0 \Rightarrow \xi_i^* = 0$ y $y_i (\langle w^*, x_i \rangle + b^*) = 1$. De aquí puede recuperarse

$$b^* = y_i - \sum_{j=1}^m \alpha_j^* y_j \langle x_j, x_i \rangle,$$

promediando sobre tales i para mayor estabilidad numérica.

- Si $\alpha_i^* = Cp_i$, el punto puede estar dentro del margen ($\xi_i^* \geq 0$) o mal clasificado.
- Si $\alpha_i^* = 0$, el punto queda fuera del margen con holgura.

Por ultimo con un núcleo K , basta reemplazar $\langle x_i, x_j \rangle$ por $K(x_i, x_j)$ en (2). La función de decisión es

$$f(x) = \sum_{i=1}^m \alpha_i^* y_i K(x_i, x) + b^*, \quad \hat{y} = \text{sign}(f(x)).$$

Veamos un poco de interpretación de p_i . Las prioridades p_i actúan como *pesos de costo* al fijar el tope dual $0 \leq \alpha_i \leq Cp_i$. Valores grandes de p_i permiten mayores α_i y, por tanto, dan más peso al punto x_i en w^* ; si $p_i = 0$, necesariamente $\alpha_i = 0$ y el punto no afecta al clasificador. $\square$

5. (20 puntos) Considere la función hinge $\ell(u) = \max\{0, 1 - u\}$. Demuestre que la función de riesgo empírico es convexa en (w, b) :

$$L(w, b) = \frac{1}{m} \sum_{i=1}^m \ell(y_i (\langle w, x_i \rangle + b)).$$

Proposición .6 (Convexidad del riesgo empírico con pérdida *hinge*). Sea $\ell(u) = \max\{0, 1 - u\}$ y, para datos $\{(x_i, y_i)\}_{i=1}^m$ con $y_i \in \{\pm 1\}$, defínase

$$L(w, b) = \frac{1}{m} \sum_{i=1}^m \ell(y_i (\langle w, x_i \rangle + b)).$$

Entonces L es convexa en (w, b) (esto es, convexa conjuntamente en $w \in \mathbb{R}^d$ y $b \in \mathbb{R}$).

Demostración. Primero, notemos que la función ℓ es convexa en su argumento escalar. En efecto,

$$\ell(u) = \max\{0, 1 - u\} = \max\{f_1(u), f_2(u)\},$$

donde $f_1(u) \equiv 0$ y $f_2(u) = 1 - u$ son funciones afines (por tanto convexas). El máximo punto a punto de funciones convexas es convexo; por lo tanto, ℓ es convexa.

El argumento interno depende linealmente de (w, b) . Para cada i , definimos

$$g_i(w, b) = y_i(\langle w, x_i \rangle + b) = \langle (y_i x_i, y_i), (w, b) \rangle,$$

de modo que g_i es una aplicación afín en la variable conjunta (w, b) .

Usamos ahora la regla de composición: si ϕ es convexa y g es afín, entonces $\phi \circ g$ es convexa. Así, para cualquier $\lambda \in [0, 1]$ y $(w_1, b_1), (w_2, b_2)$,

$$\begin{aligned} \ell(g_i(\lambda(w_1, b_1) + (1 - \lambda)(w_2, b_2))) &= \ell(\lambda g_i(w_1, b_1) + (1 - \lambda)g_i(w_2, b_2)) \\ &\leq \lambda \ell(g_i(w_1, b_1)) + (1 - \lambda) \ell(g_i(w_2, b_2)), \end{aligned}$$

donde la primera igualdad usa la afinidad de g_i y la desigualdad la convexidad de ℓ . Con esto, cada término $(w, b) \mapsto \ell(g_i(w, b))$ es convexo.

Por último, el promedio de funciones convexas es convexo. En particular,

$$L(w, b) = \frac{1}{m} \sum_{i=1}^m \ell(y_i(\langle w, x_i \rangle + b))$$

es convexa en (w, b) .

(*Notita*) Si definimos $z := (w, b) \in \mathbb{R}^{d+1}$ y $a_i := (y_i x_i, y_i)$, entonces $L(z) = \frac{1}{m} \sum_{i=1}^m \ell(\langle a_i, z \rangle)$, que es la suma de composiciones de una función convexa con aplicaciones afines, lo cual enfatiza la convexidad conjunta.

□