



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO.

IIMAS

Procesamiento del Lenguaje Natural Avanzado

Semestre 2026-1.

Dra. Helena Gómez Adorno

Dr. Fazlourrahman Balouchzahi

Practica 2: Similitud semántica: WordNet vs Embeddings

Integrantes:

- Villalón Pineda Luis Enrique

1. Introducción

Se estudia la similitud semántica entre pares de palabras en inglés usando dos enfoques: (i) métodos basados en un recurso léxico (WordNet) y (ii) métodos basados en representaciones distribucionales (embeddings). Se evalúa el rendimiento comparando las similitudes calculadas con un *gold standard* de similitud humana mediante correlación de Pearson.

2. Datasets

- **Miller–Charles (MC30)**: 30 pares de palabras con puntuaciones humanas de similitud.
- **WordSimilarity-353 (WS353)**: 353 pares de palabras con puntuaciones humanas de similitud.

3. Parte 1: Similitud con WordNet

3.1. Métricas usadas

- **Path similarity**
- **Wu & Palmer**
- **Leacock–Chodorow**

3.2. Resolución de ambigüedad léxica (WSD)

Sin contexto, se usó la estrategia:

Máximo entre sentidos: se calcula la similitud para todas las combinaciones de synsets compatibles (mismo POS: noun/verb) y se toma el máximo valor válido.

3.3. Librerías

Se usó `nltk.corpus.wordnet` para synsets y similitudes.

4. Parte 2: Similitud con Embeddings (coseno)

4.1. Modelos usados (exactos)

- **fastText**: `fasttext-wiki-news-subwords-300` (300 dimensiones)
- **GloVe**: `glove-wiki-gigaword-50` (50 dimensiones)

4.2. Estrategia de extracción del vector

Modelos **estáticos**: se usa directamente el vector de la palabra y la similitud coseno. Si una palabra no está en el vocabulario, se registra como `NaN`.

4.3. Librerías

`gensim.downloader` para cargar modelos y `numpy` para coseno.

5. Parte 3: Evaluación (Pearson)

Se calculó la correlación de Pearson entre similitudes de cada método y el score humano. Se reporta (r, n) , donde n es el número de pares válidos (ignorando NaN).

Cuadro 1: Correlación de Pearson (r) y número de pares válidos (n).

Dataset	Método	r (Pearson)	n
MC30	cos_fasttext	0.853	30
MC30	cos_glove50	0.482	30
MC30	lch_max	0.779	30
MC30	path_max	0.752	30
MC30	wup_max	0.778	30
WS353	cos_fasttext	0.696	352
WS353	cos_glove50	0.503	352
WS353	lch_max	0.348	350
WS353	path_max	0.379	350
WS353	wup_max	0.309	350

6. Tablas de 20 pares y similitudes (entregable)

6.1. MC30 (20 pares)

Cuadro 2: MC30: 20 pares con todas las similitudes.

EN.1	EN.2	score	path	wup	lch	fastText	GloVe
asylum	madhouse	3.61	0.500	0.952	2.944	0.500	-0.274
bird	cock	3.05	0.500	0.952	2.944	0.563	0.232
bird	crane	2.97	0.250	0.870	2.251	0.584	0.449
boy	lad	3.76	0.500	0.947	2.944	0.735	0.428
brother	monk	2.82	0.500	0.952	2.944	0.470	0.524
car	automobile	3.92	1.000	1.000	3.637	0.778	0.696
coast	shore	3.70	0.500	0.909	2.944	0.744	0.794
cord	smile	0.95	0.111	0.429	1.441	0.488	0.520
crane	implement	0.13	0.125	0.385	1.236	0.244	0.242
cushion	pillow	0.42	0.167	0.545	1.846	0.440	0.631
gem	jewel	0.87	0.200	0.667	2.028	0.503	0.465
journey	voyage	3.70	0.500	0.909	2.944	0.741	0.791
lad	brother	1.68	0.200	0.750	2.028	0.214	-0.087
magician	wizard	3.08	0.100	0.400	1.335	0.522	0.680
monk	oracle	0.89	0.062	0.211	0.863	0.345	-0.025
noon	string	0.84	0.111	0.429	1.441	0.488	0.341
oracle	sage	3.11	0.100	0.533	1.335	0.659	0.674
rooster	voyage	0.11	0.125	0.471	1.561	0.328	0.153
sage	wizard	1.16	0.056	0.111	0.752	0.420	0.394
shore	woodland	3.84	0.500	0.952	2.944	0.773	0.834

6.2. WS353 (20 pares)

Cuadro 3: WS353: 20 pares con todas las similitudes.

EN.1	EN.2	score	path	wup	lch	fastText	GloVe
admission	ticket	7.69	0.143	0.571	1.692	0.486	0.482
alcohol	chemistry	5.54	0.200	0.571	2.028	0.426	0.362
aluminum	metal	7.83	0.500	0.933	2.944	0.671	0.733
announcement	effort	2.75	0.100	0.308	1.335	0.407	0.515
announcement	news	7.56	0.200	0.667	2.028	0.595	0.687
assistant	helper	7.09	0.500	0.909	2.944	0.707	0.681
assistant	manager	4.00	0.200	0.533	2.028	0.427	0.393
assistant	secretary	5.50	0.200	0.533	2.028	0.480	0.476
attorney	lawyer	9.35	1.000	1.000	3.637	0.849	0.787
audience	spectator	7.13	0.250	0.750	2.251	0.670	0.691
bank	money	8.50	0.200	0.571	2.028	0.629	0.731
battery	energy	7.00	0.100	0.308	1.335	0.508	0.560
beam	light	7.00	0.125	0.429	1.561	0.556	0.533
beer	alcohol	7.40	0.200	0.571	2.028	0.743	0.750
bird	crane	7.38	0.250	0.870	2.251	0.584	0.449
bird	cock	7.07	0.500	0.952	2.944	0.563	0.232
bird	rooster	7.38	0.500	0.952	2.944	0.591	0.377
bird	wood	1.62	0.100	0.308	1.335	0.258	0.292
bishop	rabbi	6.69	0.200	0.667	2.028	0.513	0.526
blood	relation	8.06	0.100	0.400	1.335	0.441	0.479

7. Análisis crítico: comparación de métodos

7.1. ¿Qué método se aproxima mejor a los juicios humanos?

La comparación se realiza mediante la correlación de Pearson (Tabla 1). El método con mayor r es el que mejor reproduce la similitud humana en cada dataset. En nuestros resultados, los embeddings (especialmente fastText) presentan las correlaciones más altas, sugiere que la similitud humana está relacionada con patrones de co-ocurrencia y uso en grandes corpus.

7.2. WordNet (recurso léxico) vs embeddings (enfoque distribucional)

WordNet modela similitud, principalmente desde una perspectiva *taxonómica*: dos términos son similares si están cerca dentro de una jerarquía semántica (hiperonimia/hiponimia, LCS). Su ventaja es la **interpretabilidad**: se puede explicar la similitud por la estructura del recurso. Sin embargo, es sensible a (i) la cobertura del recurso, (ii) restricciones de POS y (iii) la estrategia de desambiguación cuando no hay contexto.

Embeddings (fastText/GloVe) capturan similitud por *uso*: palabras que aparecen en contextos similares terminan con vectores cercanos. Esto se alinea bien con juicios humanos cuando la similitud incluye asociaciones temáticas o funcionales (común en WS353), no solo relaciones jerárquicas. Su desventaja principal es la **menor interpretabilidad** y la dependencia del corpus: pueden reflejar sesgos del texto de entrenamiento y confundir similitud con asociación (p.ej., palabras relacionadas pero no sinónimas).

7.3. Diferencias entre métricas de WordNet

Entre las métricas de WordNet, **path** depende de la longitud del camino ; **Wu–Palmer** aprovecha profundidad del LCS y puede ser más estable en taxonomías; **Leacock–Chodorow** transforma la distancia con un logaritmo, lo que a veces suaviza diferencias y mejora comparabilidad. .

7.4. Diferencias entre modelos estáticos y contextualizados

Los modelos usados aquí (fastText y GloVe) son **estáticos**: asignan un único vector por palabra, mezclando sentidos. Esto afecta pares con una palabra con múltiples significados, porque la representación es un promedio implícito de usos. En contraste, modelos **contextualizados** (BERT/ELMo) producen embeddings dependientes de la oración, lo que permitiría desambiguar sentidos si se define una estrategia (oración plantilla, pooling de sub-tokens, etc.). Aunque no se implementaron en esta práctica, suelen mejorar cuando una palabra con múltiples significados domina el error.

7.5. Limitaciones y validez del experimento

(i) ausencia de contexto en los datasets, (ii) dependencia de heurísticas de WSD en WordNet, (iii) pares OOV o similitudes no definidas que reducen el n efectivo y (iv) uso exclusivo de Pearson (relación lineal).

8. Conclusiones

En esta práctica comparamos dos familias de métodos para estimar similitud semántica en pares de palabras (MC30 y WS353): **(i) métodos basados en WordNet** (path, Wu–Palmer y Leacock–Chodorow) y **(ii) métodos distribucionales** (similitud coseno con fastText y GloVe). El desempeño se evaluó mediante **correlación de Pearson** con los juicios humanos.

En nuestros resultados, el método que mejor se alineó con el *gold standard* fue el que alcanzó la mayor correlación en cada conjunto, destacando especialmente el enfoque de embeddings, en particular **fastText**. Esto tiene sentido ya que los embeddings capturan similitud basada en uso y contextos compartidos en grandes corpus, que suele parecerse a la noción humana de “qué tan parecidas suenan dos palabras en la práctica”. Además, fastText tiende a ser robusto en cobertura gracias a su modelado por sub-palabras, lo cual reduce el impacto de palabras raras o morfológicamente complejas.

Por otro lado, WordNet es bueno cuando la relación entre palabras tiene cercanía jerárquica, y su ventaja principal es la interpretabilidad: es posible explicar la similitud por la posición de los conceptos en la jerarquía. Sin embargo, el rendimiento de WordNet depende de la **desambiguación léxica**: al no contar con contexto, se recurrió a un máximo entre sentidos.

También se observó que la comparación entre MC30 y WS353 no es trivial: MC30 contiene pares más “clásicos” y en su mayoría los nominales, mientras que WS353 tiene mas variedad, entonces los embeddings suelen ayudarse mas en WS353, mientras que WordNet puede ser competitivo en aquellos que la estructura jerárquica.