

Ejercicio 1:

Considera un mecanismo de atención basado en producto punto (dot product attention). Dados los siguientes elementos:

- Vector de consulta $q = (1, 2)$
- Vectores clave $k_1 = (1, 1)$, $k_2 = (2, 2)$ y $k_3 = (3, 1)$
- Vectores de valor $v_1 = (2, 0)$, $v_2 = (0, 2)$, y $v_3 = (1, 1)$

Realiza lo siguiente:

1. Calcula el producto punto de q con cada vector clave k_i .
2. Aplica la función *softmax* para obtener los puntajes de atención (*attention scores*).
3. Calcula la salida final como una suma ponderada de los vectores de valor.
4. ¿Cómo afectaría a los resultados el uso de *scaled dot product attention* (es decir, dividir los puntajes de atención entre $\sqrt{d_k}$)? Explica brevemente.

$$1) q \cdot k = q_1 k_{11} + q_2 k_{12}$$

$$\text{con } k_1 \Rightarrow (1, 2) \cdot (1, 1) = 1(1) + 2(1) = 3$$

$$\text{con } k_2 \Rightarrow (1, 2) \cdot (2, 2) = 1(2) + 2(2) = 6$$

$$\text{con } k_3 \Rightarrow (1, 2) \cdot (3, 1) = 1(3) + 2(1) = 5$$

$$\Rightarrow \text{scores de atención } (3, 6, 5)$$

$$2) \text{ Aplicamos Softmax}$$

$$\text{Softmax}(x_i) = \frac{e^{x_i}}{\sum e^{x_j}} \quad e^3 \approx 20.09 \quad e^6 \approx 403.43 \quad e^5 \approx 148.41$$

$$\Rightarrow \Sigma = 20.09 + 403.43 + 148.41 = 571.93$$

pesos de atención

$$\alpha_1 = \frac{20.09}{571.93} \approx 0.035$$

$$\alpha_2 = \frac{403.43}{571.93} \approx 0.705$$

$$\alpha_3 = \frac{148.41}{571.93} \approx 0.259$$

$$\Rightarrow \text{pesos de atención } (0.035, 0.705, 0.259)$$

$$3) \text{ Salida final}$$

$$v_1 = (2, 0) \quad v_2 = (0, 2) \quad v_3 = (1, 1)$$

$$\Sigma \alpha_i v_i$$

$$0.035(2) + 0.705(0) + 0.259(1) = 0.329$$

$$0.035(0) + 0.705(2) + 0.259(1) = 1.669$$

$$\text{output} \approx (0.329, 1.669)$$

$$4) \text{ Se usa } \frac{q \cdot k}{\sqrt{d_k}} \quad \text{donde } d_k = 2$$

$$\Rightarrow (3, 6, 5) / 1.414 \Rightarrow (2.12, 4.24, 3.54)$$

Esto evita que el producto punto crezca demasiado cuando la dimensión es grande. Así los pesos de atención no se concentran en un solo vector

Ejercicio 2:

Los Transformers utilizan mecanismos de atención en lugar de recurrencia o convoluciones.

1. ¿Por qué la autoatención (*self-attention*) es más paralelizable que las RNN?
2. ¿Cómo maneja la atención las dependencias de largo alcance mejor que las CNN?
3. ¿Cuáles son algunas posibles desventajas de los mecanismos de atención?

- 1) La autoatención es más paralelizable que las RNN por que no procesa la secuencia paso a paso. En lugar de depender del estado anterior, puede calcular simultáneamente las relaciones entre todos los tokens mediante operaciones matriciales, lo que permite aprovechar mejor el paralelismo en GPU.
- 2) La atención maneja mejor las dependencias de largo alcance que las CNN por que cada token puede relacionarse directamente con cualquier otro token de la secuencia, sin importar la distancia. En cambio, las CNN trabajan con ventanas locales y necesitan varias capas para capturar relaciones lejanas.
- 3) Algunas desventajas de los mecanismos de atención son su alto costo computacional y de memoria, ya que comparan todos los tokens entre sí, lo que su complejidad crezca cuadráticamente con la longitud de la secuencia. Además suelen requerir muchos datos y recursos para entrenarse adecuadamente.

Ejercicio 3:

Supongamos que tenemos un transformer con dos cabezas de atención, cada una aprendiendo distintos aspectos de las relaciones entre palabras.

1. ¿Por qué múltiples cabezas mejoran el rendimiento?
2. ¿En qué se diferencia la atención multi-cabeza de simplemente ejecutar un único mecanismo de atención dos veces?
3. Dada la oración *The cat lay on the couch*, explica cómo una cabeza de atención podría capturar relaciones sintácticas mientras otra captura relaciones semánticas dentro de la oración.

- 1) Las múltiples cabezas de atención mejoran el rendimiento por cada una aprende diferentes tipos de relaciones entre palabras, permitiendo capturar distintos patrones como dependencias sintácticas y semánticas al mismo tiempo.
- 2) En multi-head attention:
Cada cabeza usa proyecciones distintas:
 $Q_i = XW_i^Q \quad K_i = XW_i^K \quad V_i = XW_i^V$
Es decir, cada cabeza ve una representación diferente de los datos, después las cabezas se conectan y combinan
si ejecutas una sola atención dos veces usaras los mismos parámetros y misma rela-

ción aprendida. No tendrás dos enfoques distintos

3) Cabeza 1: Relaciones sintácticas

↳ Puede aprender relaciones gramaticales

- Ejemplo -

cat → lay (relación sujeto-verbo)

lay → on (verbo con preposición)

Ayuda al modelo a entender la estructura de la oración

Cabeza 2: Relaciones semánticas

↳ Puede enfocarse en el significado

- Ejemplo -

cat ↔ couch (Relación conceptual: Un gato puede estar sobre el sofá)

lay ↔ couch (La acción de recostarse se relaciona con el sofá)

Captura las relaciones de significado entre palabras

Ejercicio 4:

Dada la oración: *The cat sat on the mat*, imagina que un mecanismo de autoatención asigna los siguientes pesos para la palabra **cat**:

Palabra Puntaje de atención

The	0.1
cat	0.4
sat	0.3
on	0.1
the	0.05
mat	0.05

1. Interpreta qué significan estos pesos.

2. ¿Cuáles podrían ser las razones por las que **sat** recibe un puntaje alto?

1) Los pesos nos dicen cuanta importancia le da el modelo a cada palabra de la oración cuando está procesando la palabra **cat**. Combina información de todas las palabras de la oración ponderadas por estos valores.

cat (0.4) → Enfoca mucho en sí mismo

sat (0.3) → El verbo relacionado con el sujeto

The (0.1) → Que acompaña el sustantivo

on (0.1) → Parte de la estructura sintáctica de la oración

2) La palabra **sat** recibe un alto puntaje alto por que tiene una fuerte relación sintáctica y semántica con **cat**, ya que funciona como el verbo cuyo sujeto es **cat**. Por ello, el modelo le asigna mayor peso al capturar el significado de la oración.

Ejercicio 5:

Dadas las puntuaciones de atención para dos cabezas diferentes en un mecanismo de atención multi-cabeza, la siguiente tabla muestra los puntajes asignados por cada cabeza a la palabra jumps en la oración:

The quick brown fox jumps over the lazy dog

Palabra	Head 1	Head 2
The	0.1	0.05
quick	0.1	0.05
brown	0.1	0.05
fox	0.4	0.1
jumps	0.2	0.3
over	0.05	0.1
the	0.05	0.15
lazy	0.05	0.2
dog	0.05	0.05

Responde lo siguiente:

- 1. ¿Cómo reflejan estas distribuciones de atención los diferentes roles de cada cabeza de atención? ¿En qué se enfoca la primera cabeza y qué enfatiza la segunda?
- 2. ¿Cómo podrían los puntajes de atención de estas dos cabezas ayudar a mejorar la capacidad del modelo para capturar tanto relaciones locales como globales en la oración?

1) Cada cabeza aprende un tipo distinto de relación lingüística

Cabeza 1

Pesos principales fox → 0.4 jumps → 0.2 The/quick/brown → 0.1

↳ Se enfoca en el sujeto del verbo y relaciones sintácticas locales

↳ El Head 1 se enfoca en la estructura gramatical alrededor del sujeto

Cabeza 2

Pesos: jumps → 0.2 lazy → 0.2 the → 0.15 over → 0.1 Fox → 0.1

↳ Se enfoca en la parte de la oración que describe el destino o contexto de la acción

Es decir jumps → over the lazy dog

Captura relaciones semánticas o de complemento del verbo

2) Tener múltiples cabezas permite que el modelo analice la oración desde diferentes perspectivas simultáneamente

Cabeza 1

↳ Captura la estructura local del sujeto

Cabeza 2

↳ Captura la estructura completa del evento descrito por el verbo

El modelo puede entender quién realiza la acción y entender sobre qué ocurre la acción
Si solo fuera una sería más difícil capturar ambos tipos de relaciones al mismo tiempo

