



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO.

IIMAS

Procesamiento del Lenguaje Natural Avanzado

Semestre 2026-1.

Dra. Helena Gómez Adorno

Dr. Fazlourrahman Balouchzahi

Tarea 6.1: Análisis de artículos

Integrantes:

- Villalón Pineda Luis Enrique

1. Introducción

El artículo *Complexity-aware fine-tuning* estudia cómo adaptar modelos de lenguaje pequeños a tareas de pregunta-respuesta sin asumir que todos los ejemplos de entrenamiento merecen el mismo tratamiento. El punto de partida es una observación bastante concreta: aunque la destilación con *chain-of-thought* permite transferir capacidad de razonamiento desde modelos grandes, hacerlo sobre todo el dataset resulta caro tanto en llamadas al modelo maestro como en volumen de datos generados.

El trabajo apunta a mejorar dos cosas a la vez: la precisión del modelo resultante y la eficiencia del proceso de entrenamiento. La apuesta es identificar primero qué preguntas son genuinamente difíciles para el modelo estudiante, y reservar la destilación de razonamiento solo para esas. Las preguntas fáciles o intermedias, en cambio, pueden aprenderse con ajuste supervisado estándar sin mayor pérdida de calidad.

La contribución concreta es una tubería automática que: (i) estima la complejidad de cada ejemplo usando la entropía del token de respuesta, (ii) divide los datos en grupos de dificultad, y (iii) aplica estrategias de entrenamiento distintas según ese grupo: SFT estándar para los ejemplos regulares y destilación de razonamiento para los difíciles. Los experimentos muestran que este esquema supera al SFT estándar en promedio (0,58 vs. 0,45) y también mejora ligeramente a la destilación total (0,58 vs. 0,56) usando un 81 % menos de datos procesados.

2. Trabajo relacionado

El trabajo se ubica en la intersección de tres líneas de investigación. La primera es el aprendizaje sensible a la complejidad de los datos, donde destacan los enfoques de *curriculum learning* que presentan ejemplos progresivamente más difíciles. Estos métodos pueden mejorar algo el desempeño, pero sus ganancias suelen ser modestas y bastante sensibles a cómo se defina la dificultad de cada ejemplo.

La segunda línea es la selección de datos de alta calidad. Trabajos como *LIMA* muestran que un conjunto pequeño pero bien curado puede producir mejoras fuertes en modelos grandes. *SmallTo-Large (S2L)* va un paso más allá y usa modelos pequeños para seleccionar subconjuntos útiles para modelos más grandes. El problema es que ninguno de estos enfoques define políticas de entrenamiento distintas según el nivel de dificultad de cada ejemplo.

La tercera línea corresponde a la estimación de complejidad o incertidumbre. Hay trabajos que exploran métodos basados en entropía y probabilidades de secuencia, y otros que usan *model-as-judge* (MASJ), donde se le pide a un LLM que estime directamente cuán difícil es un ejemplo. La entropía token a token resulta ser una señal razonable de dificultad, pero hasta este trabajo no se había integrado en una tubería de entrenamiento que realmente actuara sobre esa señal.

3. Metodología

La metodología tiene tres etapas. Primero, para cada pregunta del conjunto de entrenamiento, el modelo estudiante genera una distribución de probabilidad sobre la respuesta, y con esa distribución se calcula la entropía del token de respuesta. La hipótesis es directa: más incertidumbre del modelo implica mayor complejidad del ejemplo.

Segundo, los datos se ordenan por entropía y se dividen en tres grupos: fácil, medio y difícil. Para el entrenamiento, fácil y medio se fusionan en un grupo llamado *regular data*, mientras que el

cuarto superior de entropía forma el grupo *hard*. La lógica del corte es simple: primer cuarto como fácil, mitad central como medio, último cuarto como difícil.

Tercero, cada grupo recibe un tratamiento distinto. Los datos regulares se entrenan con SFT estándar usando pérdida de entropía cruzada. Para los datos difíciles, un LLM grande genera primero una cadena de razonamiento, y luego el modelo pequeño se entrena sobre esa secuencia razonada más la respuesta final. El resultado es un esquema híbrido: entrenamiento directo donde alcanza, y razonamiento destilado donde hace falta.

El artículo también compara varias alternativas para estimar complejidad: entropía del token de respuesta con o sin *chain-of-thought*, agregaciones de entropía sobre toda la respuesta razonada, y métodos MASJ que piden a un LLM estimar pasos de razonamiento o nivel educativo requerido. Al final, la señal que mejor funciona es la más simple: la entropía de una respuesta de un solo token.

4. Datasets

Los experimentos usan tres datasets bien conocidos. El primero es **MMLU-Pro**, un benchmark de opción múltiple que cubre múltiples dominios y se usa ampliamente para evaluar comprensión y razonamiento general. El segundo es **GSM8K**, una colección de problemas matemáticos verbales de nivel escolar que requieren razonamiento paso a paso. El tercero es **MedMCQA**, un dataset grande de preguntas médicas de opción múltiple construido a partir de exámenes reales de admisión en medicina.

La elección de estos tres datasets permite probar la propuesta en tipos de tareas bastante distintos: razonamiento sobre conocimiento general, razonamiento matemático en lenguaje natural, y comprensión de dominio especializado. Los tres son tareas de PLN centradas en *question answering*, que es exactamente el foco del artículo.

5. Configuración experimental

Los experimentos se realizan sobre tres modelos pequeños de código abierto: **Qwen2.5-3B**, **Phi-4-Mini** y **Llama 3.2 3B**. Trabajar con modelos de alrededor de 3B parámetros tiene dos justificaciones: hace los experimentos reproducibles y sitúa el problema en un escenario donde la destilación de razonamiento tiene sentido, esto es, cuando un modelo pequeño intenta aproximar el comportamiento de uno mucho mayor.

Para generar las cadenas de razonamiento sobre los ejemplos difíciles se usa un ensemble de tres modelos maestros: *DeepSeek-V3-0324*, *Qwen 3 235B* y *Llama 4 Maverick*. Los datos se dividen en entrenamiento, validación y prueba con proporción 70:10:20, y dentro de cada partición se balancean los grupos de complejidad para que tengan el mismo tamaño.

Se comparan cinco configuraciones. **Pipeline (ours)**: SFT en los datos regulares durante la primera fase, destilación en los difíciles durante la segunda. **Alternative**: la lógica invertida, SFT en difíciles y destilación en fáciles/medios. **SFT** estándar sobre todo el dataset sin ninguna división. **Curriculum**: entrenamiento secuencial de fácil a difícil. **Distillation**: destilación con razonamiento sobre todo el dataset, que sirve como baseline fuerte pero costoso.

El entrenamiento corre por 10 o 20 épocas según el experimento. Cuando hay razonamiento en el entrenamiento, la primera mitad de las épocas va al grupo regular y la segunda al grupo difícil con destilación. La métrica principal es *accuracy*, y el criterio de complejidad elegido es la **single-token entropy**, que mostró mejor ROC AUC y mayor coherencia con el desempeño posterior.

6. Resultados

Los resultados son consistentes: la propuesta supera al SFT estándar en todos los casos y, en varios, iguala o supera a la destilación completa consumiendo muchos menos tokens. En **MMLU-Pro** a 20 épocas, el método obtiene 0,52 con Qwen 3B y 0,64 con Phi-4-mini, frente a 0,39 y 0,51 para SFT, y 0,50 y 0,63 para destilación total. En **GSM8K**, llega a 0,82 con Llama 3B y 0,89 con Phi-4-mini, comparado con 0,13 y 0,19 para SFT y 0,79 y 0,89 para destilación. En **MedMCQA**, obtiene 0,56 con Llama 3B y 0,58 con Phi-4-mini, frente a 0,51 y 0,51 para SFT y 0,56 y 0,57 para destilación.

En los experimentos de 10 épocas sobre MMLU-Pro la diferencia en eficiencia es llamativa. Con Qwen 3B, el pipeline logra 0,50 de accuracy procesando unos 3,99k tokens; la destilación completa llega a 0,49 usando 19,72k tokens. Con Phi-4-mini, el pipeline obtiene 0,60 con 2,68k tokens frente a 0,63 con 15,15k de la destilación total. El ahorro reportado está entre el 79 % y el 82 % de tokens procesados.

También es relevante que el método *Alternative* —destilación en fáciles, SFT en difíciles— funcione peor que la propuesta principal. Ese resultado respalda la hipótesis central: el razonamiento explícito pierde su valor si se gasta indiscriminadamente. El *curriculum learning*, por su parte, resulta más inestable y sensible a hiperparámetros.

En cuanto a la estimación de complejidad, la **single-token answer entropy** es la señal más útil, con ROC AUC de hasta 0,73 en la formulación resumida y hasta 0,8 en análisis extendido. Los métodos MASJ y las agregaciones sobre cadenas de razonamiento completas rinden peor para separar ejemplos fáciles de difíciles.

7. Conclusiones

El artículo defiende que la complejidad de los ejemplos debería determinar la estrategia de entrenamiento, no ser ignorada. La idea validada es que no todos los ejemplos necesitan el mismo trato: para preguntas fáciles y medias, el SFT directo suele bastar; para las difíciles, la destilación de razonamiento aporta algo que el SFT solo no puede dar. Esa combinación permite usar mejor el presupuesto de entrenamiento y de tokens.

Otro resultado que los autores destacan es que la entropía del token de respuesta funciona mejor que alternativas más sofisticadas para estimar dificultad. No hace falta un juez externo ni cadenas de razonamiento complejas para separar los ejemplos: basta con la distribución de probabilidad que el propio modelo estudiante produce sobre el token de respuesta. Eso vuelve al pipeline completamente automatizable y relativamente barato de implementar.

8. Análisis crítico

8.1. Análisis de la estrategia

La propuesta funciona porque parte de algo que parece obvio pero raramente se explota en la práctica: que el costo de entrenar con razonamiento destilado no vale la pena en ejemplos que el modelo ya puede resolver bien con entrenamiento estándar. Gastar cadenas de *chain-of-thought* largas en preguntas fáciles es un derroche de cómputo que apenas mueve la aguja. Concentrar ese presupuesto en los casos donde el modelo genuinamente flaquea tiene más sentido, y los números del paper lo confirman.

Hay algo inteligente también en cómo se define la dificultad. En lugar de usar una etiqueta externa o una heurística de dominio, se mide la incertidumbre del propio modelo estudiante. Eso

hace que la separación sea adaptativa: una pregunta no es difícil en abstracto, sino difícil para ese modelo en ese momento del entrenamiento. Esa granularidad le da al pipeline cierta flexibilidad que métodos más rígidos no tienen.

Frente a otras aproximaciones, la ventaja más clara es la eficiencia. El método logra resultados comparables a la destilación total usando una fracción de los datos enriquecidos con razonamiento. Y supera al SFT estándar sin el costo de procesar cadenas largas en todo el dataset. También evita buena parte de la fragilidad del curriculum learning, que tiende a ser sensible al orden de presentación de los datos.

Sobre escalabilidad, la propuesta es más manejable que destilar sobre todo el corpus, pero sigue requiriendo un modelo maestro de calidad para generar los razonamientos de los ejemplos difíciles. No es un método autónomo ni barato del todo: escala mejor que la destilación masiva, pero el costo del teacher sigue ahí.

8.2. Debilidades del trabajo

La evaluación se hace exclusivamente en modelos de $\sim 3\text{B}$ parámetros y en tareas de *question answering*. Eso es razonable para el objetivo del paper, pero deja sin respuesta si la misma lógica funciona con modelos más grandes, en tareas generativas abiertas o en dominios donde las respuestas no son tokens discretos. El alcance real del método todavía está por probarse fuera de ese nicho.

La dependencia del teacher externo es otra limitación real. En entornos con pocos recursos, acceder a un LLM grande de calidad puede no ser posible, o puede serlo a un costo prohibitivo. Y si el teacher genera razonamientos imprecisos o inconsistentes, la fase de destilación sobre ejemplos difíciles pierde parte de su valor. El pipeline hereda los errores del modelo que lo alimenta.

Hay también una fragilidad inherente en usar entropía como proxy de dificultad. Una entropía baja significa que el modelo asigna alta probabilidad a un token, pero eso no garantiza que ese token sea correcto. El modelo puede estar muy seguro y estar equivocado. En esos casos, el pipeline etiqueta mal el ejemplo y le aplica SFT directo cuando quizá necesitaba razonamiento. La señal es útil, pero ruidosa.

El diseño experimental también deja algunas preguntas sin tocar. El corte en tres grupos iguales y la fusión de fácil+medio contra difícil es una decisión ad hoc que no se contrasta con otras proporciones. No hay ablación sobre si un corte diferente —digamos, el 10 % más difícil versus el 90 % restante— daría mejores resultados. Los autores lo reconocen, pero no llegan a explorarlo.

8.3. Propuestas de mejora

Lo primero que valdría la pena explorar son otros criterios de corte. En lugar de dividir el dataset en tres partes fijas y mandar el último cuarto a destilación, se podrían aprender umbrales automáticamente o ajustar la proporción según el dataset. Una fracción más pequeña pero más “pura” de ejemplos difíciles podría dar mejor relación costo-beneficio, especialmente cuando el teacher es caro.

También sería valioso extender los experimentos a tareas más variadas: NLI, QA extractivo, clasificación textual, generación abierta. El paper ya demuestra que la idea funciona en MCQA y razonamiento matemático, pero confirmar que la entropía del token final sigue siendo una señal útil en tareas donde la respuesta no es discreta sería un avance importante para saber hasta dónde escala la propuesta.

Una ablación más profunda sobre el tipo de razonamiento destilado también añadiría claridad. No es lo mismo destilar CoT largos que CoT compactos, y no está claro si otras técnicas de apoyo

inferencial darían resultados similares. Los propios autores señalan que no exploraron esa dimensión, y es una extensión natural del trabajo.

Por último, mejorar la calidad de la señal de incertidumbre parece una palanca importante. Si la entropía es el núcleo del método, calibrarla mejor podría mejorar toda la tubería. Se podría combinar con otras señales o aplicar técnicas de calibración de probabilidades, siempre cuidando no añadir tanta complejidad que se pierda la sencillez que hace atractivo al método en primer lugar.